

Analiza temperatury ciała mężczyzn i kobiet – testy statystyczne i porównanie rozkładów

Dane:

```
dane <- read.table("tempciala.txt", header = TRUE, sep = ",")

dane_M = dane[dane$plec == 1, "temperatura"]
dane_K = dane[dane$plec == 2, "temperatura"]
```

Średnia i odchylenie:

```
mean_M = mean(dane_M)
mean_K = mean(dane_K)

sd_M = sd(dane_M)
sd_K = sd(dane_K)

wyniki1 <- data.frame(
  "Płeć" = c("mężczyźni", "kobiety"),
  "Średnia temperatura" = c(mean_M, mean_K),
  "Odchylenie standardowe temperatury" = c(sd_M, sd_K)
)
print(wyniki1)
```

```
##      Płeć Średnia.temperatura Odchylenie.standardowe.temperatury
## 1 mężczyźni      36.72615      0.3882158
## 2  kobiety      36.88923      0.4127359
```

Mężczyźni:

```
n = 65
mi_0 = 36.6; alfa = 0.05

T1 = abs(mean_M - mi_0)*sqrt(n)/sd_M   # T = statystyka testowa
c1 = qt(1 - alfa/2, df = n-1)         # c = wartość krytyczna , df = liczba stopni swobody
p_val1 = 2*(1 - pt(T1, df = n-1))     # p_val = wartość p

print(T1)
```

```
## [1] 2.619895
```

```
print(c1)
```

```
## [1] 1.99773
```

```
print(p_val1)
```

```
## [1] 0.01097201
```

Wartość statystyki $T = 2.6199$.

Wartość krytyczna dla poziomu istotności $\alpha = 0.05$ wynosi $c = 1.9977$.

p-wartość = 0.011.

Kobiety:

```
n = 65
mi_0 = 36.6; alfa = 0.05

T2 = abs(mean_K - mi_0)*sqrt(n)/sd_K
```

```

c2 = qt(1 - alfa/2, df = n-1)
p_val2 = 2*(1 - pt(T2, df = n-1))

print(T2)

```

```
## [1] 5.649745
```

```
print(c2)
```

```
## [1] 1.99773
```

```
print(p_val2)
```

```
## [1] 3.985272e-07
```

Wartość statystyki T = 5.6497.

Wartość krytyczna dla poziomu istotności $\alpha = 0.05$ wynosi c = 1.9977.

p-wartość = 0.

Wykorzystanie funkcji t.test:

```

TM = t.test(dane_M, mu = mi_0, alternative = "two.sided")
TK = t.test(dane_K, mu = mi_0, alternative = "two.sided")

print("Test dla mężczyzn:")

```

```
## [1] "Test dla mężczyzn:"
```

```
TM
```

```

##
## One Sample t-test
##
## data: dane_M
## t = 2.6199, df = 64, p-value = 0.01097
## alternative hypothesis: true mean is not equal to 36.6
## 95 percent confidence interval:
## 36.62996 36.82235
## sample estimates:
## mean of x
## 36.72615

```

```
print("Test dla kobiet:")
```

```
## [1] "Test dla kobiet:"
```

```
TK
```

```

##
## One Sample t-test
##
## data: dane_K
## t = 5.6497, df = 64, p-value = 3.985e-07
## alternative hypothesis: true mean is not equal to 36.6
## 95 percent confidence interval:
## 36.78696 36.99150
## sample estimates:
## mean of x
## 36.88923

```

Mężczyźni: Wartość $p = 0.01097$ jest mniejsze od $\alpha = 0.05$ co oznacza, że odrzucamy hipotezę zerową.

Kobiety: Wartość $p = 3.985e-07$ jest mniejsze od $\alpha = 0.05$ co oznacza, że odrzucamy hipotezę zerową.

```
wyniki2 <- data.frame(  
  "Płeć" = c("mężczyźni", "kobiety"),  
  "statystyka testowa" = c(T1, T2),  
  "wartość krytyczna" = c(c1, c2),  
  "wartość p" = c(p_val1, p_val2)  
)  
print(wyniki2)
```

```
##      Płeć statystyka.testowa wartość.krytyczna  wartość.p  
## 1 mężczyźni      2.619895      1.99773 1.097201e-02  
## 2  kobiety      5.649745      1.99773 3.985272e-07
```

Testy normalności dla zarejestrowanych temperatur: a - Test Kołmogorowa-Smirnowa:

```
KS_M = ks.test(dane_M, 'pnorm', mean = mean_M, sd = sd_M)
```

```
## Warning in ks.test(dane_M, "pnorm", mean = mean_M, sd = sd_M): ties should not  
## be present for the Kolmogorov-Smirnov test
```

```
KS_K = ks.test(dane_K, 'pnorm', mean = mean_K, sd = sd_K)
```

```
## Warning in ks.test(dane_K, "pnorm", mean = mean_K, sd = sd_K): ties should not  
## be present for the Kolmogorov-Smirnov test
```

```
KS_M
```

```
##  
## One-sample Kolmogorov-Smirnov test  
##  
## data: dane_M  
## D = 0.088528, p-value = 0.6883  
## alternative hypothesis: two-sided
```

```
KS_K
```

```
##  
## One-sample Kolmogorov-Smirnov test  
##  
## data: dane_K  
## D = 0.12018, p-value = 0.3049  
## alternative hypothesis: two-sided
```

b - Test D'Agostino na skośność:

```
library(moments)  
a_M = agostino.test(dane_M)  
a_K = agostino.test(dane_K)  
a_M
```

```
##  
## D'Agostino skewness test  
##  
## data: dane_M  
## skew = -0.27047, z = -0.96033, p-value = 0.3369  
## alternative hypothesis: data have a skewness
```

```
a_K
```

```
##  
## D'Agostino skewness test  
##  
## data: dane_K  
## skew = 0.011492, z = 0.041338, p-value = 0.967  
## alternative hypothesis: data have a skewness
```

```
c - Test Anscombe-Glynn-a na kurtozę:
```

```
ag_M = anscombe.test(dane_M)  
ag_K = anscombe.test(dane_K)  
ag_M
```

```
##  
## Anscombe-Glynn kurtosis test  
##  
## data: dane_M  
## kurt = 2.61353, z = -0.45595, p-value = 0.6484  
## alternative hypothesis: kurtosis is not equal to 3
```

```
ag_K
```

```
##  
## Anscombe-Glynn kurtosis test  
##  
## data: dane_K  
## kurt = 4.4251, z = 2.1139, p-value = 0.03453  
## alternative hypothesis: kurtosis is not equal to 3
```

```
d - Test Jarque-Bera:
```

```
j_M = jarque.test(dane_M)  
j_K = jarque.test(dane_K)  
j_M
```

```
##  
## Jarque-Bera Normality Test  
##  
## data: dane_M  
## JB = 1.197, p-value = 0.5496  
## alternative hypothesis: greater
```

```
j_K
```

```
##  
## Jarque-Bera Normality Test  
##  
## data: dane_K  
## JB = 5.5021, p-value = 0.06386  
## alternative hypothesis: greater
```

```
e - Test Shapiro-Wilka:
```

```
sh_M = shapiro.test(dane_M)  
sh_K = shapiro.test(dane_K)  
sh_M
```

```
##  
## Shapiro-Wilk normality test  
##  
## data: dane_M  
## W = 0.98238, p-value = 0.4818  
sh_K
```

```
##  
## Shapiro-Wilk normality test  
##  
## data: dane_K  
## W = 0.95981, p-value = 0.03351
```